Heng Shi

codefisheng@gmail.com · 首席研究员 / 首席 AI 官 · Ph.D., B.Sc., sMIEEE, MACM · mobiles 18001713237

个人简述

- 领域：AI Infra · Compiler & PL · 高性能计算 · Agent 系统
- 工程与带队：
  - 团队组建：两次从 0 组建团队——算法工程团队（30+ 人）与 AI Infra 研究团队（10 人）
  - 技术路线：软件栈架构设计（TopsRider 1.0/2.0）；负责研究院全部研究路线及落地转化的路线规划
- 成果与影响力：
  - 论文：CCF A 类 8 篇、CCF B 类 4 篇（SC、ATC、EuroSys、ASPLOS、ASE 等），引用 1900+，H-index 11；SC'26 最佳论文提名——中国历史上仅 6 次提名、1 次最终获奖
  - 专利：授权发明专利 14 项，其中第一发明人 8 项
  - 人才计划：入选 2022 年度上海启明星人才计划、2026 年度东方英才人才计划
- 行业贡献：
  - 标准与赛事：MLCommons/MLPerf Inference、Pre-silicon、Training 工作组成员；全国先进计算技术创新大赛首届 A3 赛题出题人、第四届赛题负责人
  - 开源：发起并开源高性能编程语言 CroqTile（Apache-2.0）；参与并贡献 AI 推理框架 mistral.rs（7.8k★）、candle-vllm（741★）
  - 邀请与学术报告：中国人工智能大会 CCAI 2024、Rust China Conf 2024 邀请报告；ASPLOS'24、ASE'24、ICPP'24、EuroSys'25、PPoPP'26、ATC'26、ICPP'26、SC'26 学术报告
  - 授课：上海市集成电路紧缺人才培训项目（第 27 期）、高性能计算芯片技术高级研修班授课导师；上海交大《实时操作系统》企业导师

工作经历

燧原智能科技 | Enflame Tech., 首席 AI 官 2026.08-Present

- 统筹公司 AI 技术战略与 AI 原生研发体系；发起并主导 AI 原生工作流平台 Piano，推动算子库与多部门 Agent 工作流落地

燧原智能研究院 | Research Academy, Enflame Tech., 首席研究员 2022.12-Present

- 组建并带领 AI Infra 研究团队（10 人），主导" 编译器与 AI 代理协同设计" 技术方向，覆盖编译器基础设施、AI 代理调优与高性能计算
- 统筹技术 Roadmap 与关键研究项目攻坚，负责研究院整体技术把关、对外标准及学术论文审核

上海交通大学・可扩展计算与系统实验室, 博士后 2024.02-2026.09

- 负责面向国产芯片的下一代通用高性能计算编程语言项目研究

燧原智能科技 | Enflame Tech., 主任架构师 2021.03-2022.12

- 架构组算法方向总负责人，统筹 30+ 人算法工程团队的技术选型、软硬件协同设计与技术预研攻坚
- 负责框架上层与算法模型库的架构设计与原型实现，参与公司技术 Roadmap 制定

燧原智能科技 | Enflame Tech., 资深算法研究工程师 2020.02-2021.03

- 负责算法与框架跨领域前瞻性预研及内部性能评测标准体系，并代表公司参与 MLCommons/MLPerf 等评测标准组织

燧原智能科技 | Enflame Tech., 高级算法研究工程师 2018.11-2020.02

- 负责通用算法优化与芯片 Bring-up 算法支持，参与首代 TopsRider 1.0 软件栈研发，主导低精度训练、结构化稀疏与梯度压缩等技术原型

项目经历

Piano：可编程 AI Agent 工作流系统 | Enflame Tech., 项目负责人 2026.08-Present

- 定位与落地：首席 AI 官履新后的首个项目，发起并主导公司 AI 原生工作流平台 Piano；已用于算子库产品自动化开发并推广至多个部门的定制化 Agent 工作流；开源：https://github.com/SyntaxArchmage/piano

- **核心架构**：以 YAML v3 工作流图（`stage` / `loop` / `tournament`）组合 Agent，每个 stage 通过可配置 harness 运行，使工作流可 diff、可复用、可组合；持久化 run 状态与 append-only 证据支持崩溃恢复、人工签收与可跳过 stage
- **调优与评测**：Tournament 以隔离 worktree 并行探索策略 lane 并按 benchmark 选优，生产 run 完成 82/82 stages；Evals 飞轮把长 run 切成可恢复并行切片，评测吞吐 23×，并基于 trajectory 后训练提升 Qwen3.8-27B 的 pass@4
- **成果与交付**：首个生产负载为算子调优，`fused_sigmoid_gating` 平均 2.01×、`causal_conv1d_update` geomean 1.44× 且无回退；save-token / durable-request 代理工具落地公司 AI 工作流，ROI 提升 3 倍以上

CroqTile：AI 原生 GPU Kernel 编程语言与 Tuner | Enflame Tech., 项目负责人　2024.12-Present

- **定位与落地**：项目发起人与总体技术负责人；Apache-2.0 开源（https://github.com/LancerLab/croqtile）；作为 Choreo 编译器模块落地公司 TopsOp 算子库，ATC'26 论文一作
- **设计主线**：语言与 Agent 上下文窗口协同设计（syntax–context）、编译器与调优 harness 协同设计（compiler–harness），让 Agent 自主编写、调优并交付生产级 kernel；C++ EDSL 以 Shape 为一等公民，支持 CUDA/CuTe、HIP、C++ 多后端
- **协同设计成效**：8K 窗口下工作集约 2,370 tokens，可容纳约 60 轮调优历史，编译 pass@1 达 85.7%；结构化诊断与预编译排序淘汰 79% 配置，自主调优在 95 个生产 shape 上平均 1.23× 于 cuBLAS / CUTLASS / cuSPARSELt
- **编译器与 Tuner**：SALA（CGO'27）信号感知活性分析把共享内存降低 12–37%；Tuner 以确定性 orchestrator + 持久化 Agent session 覆盖多种 DSL，生产调优把 blockscale e4m3 GEMM 从 397.9 提升到 621.0 TFLOPS（+56.1%）

AI Infra：结构化稀疏优化 | Enflame Tech., 研究负责人　2024.12-Present

- **方向与职责**：研究负责人，团队 3 人（含 2 名博士实习生）；主导让 2:4 结构化稀疏成为 MoE 推理、长上下文注意力、Stencil 计算与稠密 GEMM 的一等算力路径，覆盖 NVIDIA Hopper 与燧原 GCU
- **系统与 Kernel 主线**：Samoyeds（EuroSys'25）实现双边稀疏 GEMM 与稀疏-稀疏 MMA kernel，kernel 层最高 1.99×；SPIDER（PPoPP'26）以 Strided / Row Swapping 将 Stencil 转为 SpTC 兼容 GEMM，较 cuDNN 平均 6.23×；SptcAttn（ATC'26）以对角条带稀疏把长上下文注意力映射到 Sparse Tensor Core
- **解析建模与自动调优**：GemmSP（SC'26，一作）建立覆盖 roofline、L2 复用、流水重叠与 wave quantization 的 2:4 稀疏 GEMM 解析模型；模型引导的 kernel 与自动调优在 80/95 个 e4m3 shape 上稳定超过 cuSPARSELt，平均 +16.7%
- **成果与落地**：5 篇论文覆盖 EuroSys、PPoPP、SC（2 篇）、ATC；SC'26 最佳论文提名——中国历史上仅 6 次提名、1 次最终获奖；开源 Samoyeds / SPIDER / SALA 等可复现仓库，稀疏能力已落地 Choreo/CroqTile

Candle 框架：面向 DSA 的适配与优化 | Enflame Tech., 项目负责人　2024.01-2025.06

- 项目负责人，团队规模 2 人；基于 Rust 实现
- 开源：https://github.com/EnflameTechnology/candle-gcu
- 开源：https://github.com/EnflameTechnology/candle-vllm-gcu
- 将 Candle 框架适配并优化到公司 DSA（GCU）后端：实现零成本扩展支持、GCU 微核与融合算子（softmax、layernorm、attention 等）、多 GCU/多节点推理、量化（AWQ/GPTQ）与页化注意力/KV Cache 优化，显著提升 LLM 推理吞吐与资源利用率
- 模型支持：覆盖十余种主流 LLM（LLaMa、Mistral、Phi、DeepSeek、QWen、Gemma 等）
- 性能：内部基准（Enflame S60）平均推理吞吐约为企业主栈 vLLM 的 95%，兼顾吞吐与资源利用率
- 工程实践：实现 GCU/GPU 无缝切换、多进程/多节点分片推理、量化模型转换工具与运行时参数调优；提供权重 Offload 等工程能力，并在真实机型上完成吞吐验证

camelus：GCU 芯片编程头文件库 | Enflame Tech., 核心开发

- **交付**：自研 GCU 芯片编程基础头文件库已交付 GCU 2.0 / GCU 3.0 两代芯片产品中，全方位支撑两代芯片的算子编程开发

自动张量化研究 | Enflame Tech., 技术预研，项目负责人　2023.06-2023.12

- 目标与方法：实现自动张量化，将张量级运算自动向量化并映射到 Intel VNNI；通过循环表示变形与编译器合法性优化，在最内层循环 / 基本块中暴露 VNNI 计算模式，提升稠密线性代数（DLA）内核性能
- 成效:通过高效内存访问与寄存器/缓存复用降低 VNNI 延迟依赖,避免仅依赖模板或繁重的 Autotuning 搜索；在 DLA 与 DNN 基准上优于工业编译器与相关研究（见 ASPLOS '24）
- **交付**：方法与原型交付公司编译器预研体系，沉淀为 ASPLOS'24 论文成果与可复用的 DLA 内核向量化路径

上海市启明星项目：大规模异构硬件场景下的人工智能编译器 | Enflame Tech., 项目负责人
2022.06-2025.09（已验收）

- 上海市 2022 年度" 科技创新行动计划" 启明星项目，项目经费 40 万元，2025 年 9 月验收通过
- 总架构师与项目负责人；该平台作为预研阶段的轻量级实验平台，用于对比实验与方案验证，支持与 GPU 的异构运行
- 架构设计：参考 IREE + JAX 的前端 Import / 编译器 / 运行时分层架构，以 Trait 机制解耦子模块；Importer 基于 Python Tracing（兼容 PyTorch / Keras，Rust + Python Binding），编译器基于 MLIR（TOSA → Linalg → Target IR，实现 Autodiff / Autofusion / Autoparallel），运行时基于 Rust 支持 CUDA / Vulkan 及自研驱动
- 代表性研究：自动微分、自动算子融合、可逆计算自动化合成、自动张量化等均基于该平台验证与对比
- **交付**：轻量级异构 AI 编译器实验平台于 2025 年 9 月通过验收并交付公司预研体系，支撑上述研究方向的对比验证

基于 Actor System 的异构计算运行时系统 | Enflame Tech., 技术预研，项目负责人
2024.01-2024.12

- 项目负责人，基于 Rust 实现；开源：https://github.com/codes1gn/Raptors
- 目标：面向异构计算任务的 Actor 运行时与调度框架，强调高并发消息驱动与可扩展执行
- 核心抽象：ActorSystem / ProtoSystem / LoggingSystem、Actor / Context、Mailbox + MessageQueue、Envelope（Message + Sender / Receiver），统一系统消息与业务消息通道
- 调度设计：Executor / ActorStream / Reactor 进行任务排队、唤醒与执行；支持异步消息传递与多线程运行时（Tokio）
- **交付**：运行时原型与 Raptors 开源仓库交付公司异构计算预研体系，为跨设备 / 跨节点调度提供可扩展执行框架

自动并行框架原型 Gemini | Enflame Tech., 项目负责人 2020.11-2021.03

- Generic Model Parallel Instrumenter — 设计并实现自动模型并行 S2S（源到源）无侵入编译方案，可在不修改模型源码的前提下对模型进行并行化插装与转换
- 基于自动代码变换原理，构建模型代码文件树并生成 AST，AST 与数据流图形式的轻量级 IR 实现互转，通过 Pass 使能模型并行 Pattern
- **交付**：原型与初版发布已交付研发项目组，代码 90% 独立完成，支撑公司自动模型并行方向的技术预研

芯片 Bring-up 与模型收敛调试 | Enflame Tech., 负责人 2019.10-2020.07

- 负责芯片 Bring-up 算法支持：设计动态精度方案，规避 Retrain 需求并绕开竞品专利限制，已申请专利
- 参与推理栈存储机制设计，负责梳理各流程数据 Layout 与转换策略
- **交付**：动态精度方案与推理栈存储设计交付首代芯片 Bring-up 与推理栈产品化流程，规避重训需求与竞品专利限制，方案已申请专利

model_inspect（Model Insight）模型调试工具 | Enflame Tech., 负责人 2019.09-2019.10

- 设计并实现分层架构：上层提供自动化数值检查与分析，底层通过 DMA 逻辑注入调试指标计算与异常现场保留回调
- 主导软件栈去随机性方案攻关；基于确定性运行前提，实现以 CPU 模拟结果为 Golden Base 的逐层 Bit-to-bit 数值对比功能
- **交付**：产品化为 model_inspect 系统工具并交付企业模型迁移与精度调试产品中，自 2021 年起持续使用

8-bit 降精度训练方案 | Enflame Tech., 技术预研，负责人 2019.05-2019.06

- 复现并改进 IBM HFP8 方案，优化模型的精度算子分类策略，实现 HFP8 训练无精度损失
- 方案一：浮点型 8-bit 格式（1-5-2 配比），通过 DMA 进行格式转换，配合 Auto Loss-scaling；相较 FP16 混精节省 30%–40% 显存，ResNet50 训练时间降低 27%–30%
- 方案二：Block Floating Point 格式（1-2-5 配比，共享全局 Exponent Head，尾数补码编码），可使用 Int ALU 执行，预期大幅降低功耗；已在 CUDA 上完成计算正确性验证
- **交付**：降精度训练方案已工程化并交付公司软件栈，配套设计硬件低精度浮点格式；整套方案已授权专利，相较 FP16 混精节省 30%–40% 显存

Elementwise 算子优化与 Dot 算子仿真建模 | Enflame Tech., 技术开发 2019.04-2019.04

- 基于燧原指令集进行 Elementwise 算子性能优化与 Profiling

- 完成 Dot 算子性能建模与 CPU 仿真
- 交付：Elementwise 优化实现与 Dot 算子仿真模型交付首代算子库研发，用于指令集性能调优与验证

调度器 Strategy Engine 设计与实现 | Enflame Tech., 技术开发 2019.02-2019.04

- 负责 Strategy Engine 模块，基于 List Scheduling 算法设计与实现启发式调度策略
- 交付：Strategy Engine 交付公司运行时调度器产品中，承担首代软件栈的任务调度

近三年论文

1. Wu, Sijie, Xiaofeng Guan, **Heng Shi**, Enmin Fan, and Jianguo Yao. "SALA: Signal-Aware Liveness Analysis for Shared Memory Optimization in Warp-Specialized GPU Kernels." *Proceedings of the 2027 IEEE/ACM International Symposium on Code Generation and Optimization (CGO '27)*, IEEE/ACM, 2027.
2. Shi, **Heng**, Qiqi Gu, Chenpeng Wu, Xiaofeng Guan, Sijie Wu, Enmin Fan, Guoqing Bao, and Jianguo Yao. "Pushing the Limits of Structured Sparse GEMM on Hopper GPUs via Analytical Modeling." *Proceedings of the International Conference for High Performance Computing, Networking, Storage and Analysis (SC '26)*, IEEE/ACM, 2026.
3. Gu, Qiqi, Chenpeng Wu, **Heng Shi**, Jianguo Yao, and Haibing Guan. "Do We Need Tensor Cores for Stencil Computations?" *Proceedings of the International Conference for High Performance Computing, Networking, Storage and Analysis (SC '26)*, IEEE/ACM, 2026. 最佳论文提名
4. Shi, **Heng**, Xiaofeng Guan, Sijie Wu, Enming Fan, Chenpeng Wu, Qiqi Gu, Jiahang Xie, Guoqing Bao, and Jianguo Yao. "A Novel AI-Native GPU Kernel Programming Language for Autonomous Kernel Tuning." *Proceedings of the 2026 ACM SIGOPS Annual Technical Conference (ATC '26)*, Association for Computing Machinery, 2026.
5. Wu, Chenpeng, Qiqi Gu, **Heng Shi**, Jianguo Yao, and Haibing Guan. "SptcAttn: Accelerating Long-Context Attention with Diagonal Stripes using Sparse Tensor Core." *Proceedings of the 2026 ACM SIGOPS Annual Technical Conference (ATC '26)*, Association for Computing Machinery, 2026.
6. Shi, **Heng**, Xiaofeng Guan, and Jianguo Yao. "Adaptive Operator Fusion with Subproblem Decomposition for Enhanced Memory Efficiency." *Proceedings of the 55th International Conference on Parallel Processing (ICPP '26)*, Association for Computing Machinery, 2026.
7. Gu, Qiqi, Chenpeng Wu, **Heng Shi**, and Jianguo Yao. "SPIDER: Unleashing Sparse Tensor Cores for Stencil Computation via Strided Swapping." *Proceedings of the 31st ACM SIGPLAN Annual Symposium on Principles and Practice of Parallel Programming (PPoPP '26)*, Association for Computing Machinery, 2026, pp. 218–231.
8. Wu, Chenpeng, Qiqi Gu, **Heng Shi**, Jianguo Yao, and Haibing Guan. "Samoyeds: Accelerating MoE Models with Structured Sparsity Leveraging Sparse Tensor Cores." *Proceedings of the Twentieth European Conference on Computer Systems (EuroSys '25)*, Association for Computing Machinery, 2025, pp. 293–310.
9. Fan, Enming, Xiaofeng Guan, Fan Hu, **Heng Shi**, Hao Zhou, and Jianguo Yao. "Postiz: Extending Post-increment Addressing for Loop Optimization and Code Size Reduction." *Proceedings of the 23rd ACM/IEEE International Symposium on Code Generation and Optimization (CGO '25)*, Association for Computing Machinery, 2025, pp. 600–613.
10. Bao, Guoqing, **Heng Shi**, Chengyi Cui, Yalin Zhang, and Jianguo Yao. "UFront: Toward A Unified MLIR Frontend for Deep Learning." *Proceedings of the 39th IEEE/ACM International Conference on Automated Software Engineering (ASE '24)*, Association for Computing Machinery, 2024, pp. 255–267.
11. Yuchi, Bowen, **Heng Shi**, and Guoqing Bao. "SPHINX: Search Space-Pruning Heterogeneous Task Scheduling for Deep Neural Networks." *Proceedings of the 53rd International Conference on Parallel Processing (ICPP '24)*, Association for Computing Machinery, 2024, pp. 524–533.
12. Zhou, Hao, Qiukun Han, **Heng Shi**, Yalin Zhang, and Jianguo Yao. "Boost Linear Algebra Computation Performance via Efficient VNNI Utilization." *Proceedings of the 29th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, Vol. 3 (ASPLOS '24)*, Association for Computing Machinery, 2024, pp. 149–163.
13. Shi, **Heng**, L Fang, X Chen, C Gu, K Ma, X Zhang, et al. "Review of the opportunities and challenges to accelerate mass-scale application of smart grids with large-language models." *IET Smart Grid*, vol. 7, no. 6, 2024, pp. 737–759.

专利

授权发明专利 14 项，其中第一发明人 8 项；另有 12 项在审（专利题名以授权证书为准）。

- 双稀疏矩阵的乘法加速方法、装置、设备、介质及产品 CN119806639A
- 混合专家模型的存储优化方法、装置、设备、介质及产品 CN119808861A

- 混合专家模型的算子优化方法、装置、设备、介质及程序 CN119830976A
- 混合专家模型的优化方法、装置、设备、介质及程序 CN119808860B
- 一种基于微算子的大模型跨平台系统 CN119718484B
- 深度学习模型可逆化的全局优化方法、装置、设备及介质 CN118657187A
- 深度学习模型的自动可逆化合成方法、装置、设备及介质 CN118364890B
- 任务运行时的动态存储管理方法、装置、设备及介质 CN118363542A
- 深度学习模型中的可逆结构识别方法、装置、设备及介质 CN118364891B
- 深度学习模型非侵入可逆化转换方法、装置、设备及介质 CN118569346A
- 一种反向计算图的静态生成方法、装置、设备及介质 CN117273115A
- 一种算子融合方法、装置、电子设备及存储介质 CN117271101A
- 于多层级代码生成的 AI 前端统一计算方法、装置及介质 CN116560666B
- 面向异构场景的 AI 统一计算方法、装置、设备及介质 CN116149797A
- 异构场景下的神经网络任务调度策略确定方法及装置 CN116166405B
- 张量程序的整程序编译方法、装置、设备、介质及集群 CN115495095B
- 深度学习模型的生成方法、优化方法、装置、设备及介质 CN113283613B
- 结构化稀疏参数的处理方法、装置、设备及存储介质 CN112508190A
- 张量浮点数据处理方法、装置、设备及存储介质 CN112130807A

奖励

- 上海市 2022 年度” 科技创新行动计划” 启明星项目入选
- SC’26 国际会议 **最佳论文提名**（中国历史上仅 6 次提名、1 次最终获奖）
- 第二届全球能源预测竞赛 GEFCOM2017，**TOP 20**，2017 年
- 英国太阳能与清洁能源奖, **最佳项目大奖**, 2016 年
- IEEE PES 智能电网通用会议, **最佳论文奖**, 2015 年
- 大学生物理竞赛（物理组），**全国一等奖**，2010 年
- 全国高中物理奥林匹克竞赛（全国总决赛），**一等奖 TOP 20**，2008 年
- 燧原科技 COO Award × 2、价值创造 Award、勇担职责 Award，2019–2020 年

开源与服务

- **国际标准**：MLCommons/MLPerf Inference、Presilicon、Training 工作组成员（2019–2021），参与全球首个 AI 性能评测框架规则制定
- **开源**：CroqTile（Apache-2.0，发起并主导）；mistral.rs / candle-vllm 上游贡献；SPIDER、Samoyeds、SALA、kebab 论文可复现仓库
- **赛事**：全国先进计算技术创新大赛首届 A3 赛题出题人、第四届赛题负责人
- **报告**：中国人工智能大会 CCAI 2024、Rust China Conf 2024 邀请报告
- **教学**：上海集成电路紧缺人才培训项目（第 27 期）、高性能计算芯片技术高级研修班授课导师；上海交大《实时操作系统》企业导师
- **人才培养**：产学研联合培养博士 1 人、硕士 7 人（中科大、西交、上交等）
- **其他**：AIIA 芯片与架构组公司代表（CCSA 行业标准共同作者）；Electronics 专刊客座编辑；上海市计算机学会会员

教育背景

英国巴斯大学, 电子与电气工程, 博士学位 2014.10 - 2018.7

博士论文评为优秀；转正答辩无修改通过（前 5%），毕业 Viva 答辩小修改通过（前 3%）

清华大学, 计算机科学与技术, 理学学士学位 2009.8 - 2013.6

入选清华大学第二届星火科技创新班；负责项目：非线性优化理论线性化技术及其在 AGV 集群调度中的最优化策略应用